

Anwendung komplexer Trainingsverfahren auf kleine CNN-Modelle

a) Perceptual Loss auf kleinen Netzwerken

Die Anwendung des Perceptual Loss auf kleine CNN-Architekturen ist grundsätzlich möglich, führt jedoch in der Praxis häufig zu eingeschränkten Ergebnissen. Der Perceptual Loss berechnet den Fehler nicht auf Pixelebene, sondern im Feature-Raum eines vortrainierten Netzwerks (meist VGG19). Dadurch soll das Modell lernen, semantische und strukturelle Merkmale eines Bildes nachzubilden, anstatt nur die exakten Intensitätswerte der Pixel. Kleine Netzwerke besitzen jedoch nur eine begrenzte Repräsentationsfähigkeit, um diese hochdimensionalen Merkmale korrekt zu rekonstruieren. Sie können einfache Texturen und Kantenstrukturen zwar annähern, aber keine komplexen semantischen Muster erfassen. Infolgedessen sinkt der Loss während des Trainings zwar sichtbar, die resultierenden Bilder bleiben jedoch häufig unscharf oder weisen feine Artefakte auf. In einer vergleichenden Untersuchung kann dies genutzt werden, um den Zusammenhang zwischen Modellkapazität und Lernfähigkeit für komplexe Verlustfunktionen zu demonstrieren. Ein mögliches Fazit lautet: „Das einfache Modell konnte die im Feature-Raum kodierten semantischen Zusammenhänge des Perceptual Loss nur unvollständig abbilden, was auf eine unzureichende Repräsentationsfähigkeit hinweist.“

b) Adversarielles Training auf kleinen Netzwerken

Das adversarielle Training (z. B. nach dem SRGAN-Prinzip) kann ebenfalls auf kleine CNN-Modelle angewendet werden, erweist sich jedoch als deutlich instabiler. Hierbei konkurrieren Generator und Diskriminator: Der Generator versucht, realistische hochaufgelöste Bilder zu erzeugen, während der Diskriminator zwischen echten und generierten Bildern unterscheidet. Kleine Netzwerke verfügen dabei nicht über die nötige Kapazität, um die vom Diskriminator geforderten hochfrequenten Details überzeugend zu rekonstruieren. Dies führt oft zu instabilem Training, Mode Collapse oder zu Bildern mit starkem Rauschen. Selbst durch eine Verringerung der Diskriminatorgröße oder Anpassung der Lernraten bleibt die Konvergenz oft schwierig. Trotz dieser Einschränkungen kann das Experiment wertvolle Erkenntnisse liefern, etwa im Hinblick auf die Grenzen adversarieller Lernziele bei ressourcenschwachen Modellen: „Das kleine Netzwerk zeigte deutliche Schwierigkeiten, die adversarielle Zielfunktion stabil zu optimieren, was auf die begrenzte Modellkapazität und die hohe Komplexität des Lernziels zurückzuführen ist.“