

# Überblick über drei Trainingsverfahren für Super-Resolution mit CNNs

In der Super-Resolution-Forschung werden verschiedene Trainingsstrategien eingesetzt, um ein Gleichgewicht zwischen numerischer Genauigkeit, visueller Qualität und Trainingsstabilität zu erreichen. Im Folgenden werden drei etablierte Verfahren beschrieben, die sich besonders gut für den Vergleich einfacher und komplexer CNN-Architekturen eignen.

## 1. L1-Loss Training (Pixel-basiertes Baseline-Verfahren)

Das L1-Loss-Verfahren minimiert den absoluten Unterschied zwischen dem generierten und dem echten Bild. Es handelt sich um die einfachste und stabilste Trainingsmethode. Sie liefert hohe PSNR-Werte und eine gleichmäßige Konvergenz, führt aber oft zu leicht weichgezeichneten Bildern. Diese Methode eignet sich hervorragend als Baseline zur Beurteilung der Leistungsfähigkeit unterschiedlicher Netzwerkarchitekturen.

## 2. Perceptual Loss (Feature-basierte Optimierung)

Der Perceptual Loss misst den Unterschied zwischen generierten und echten Bildern in einem semantischen Feature-Raum eines vortrainierten Netzwerks (meist VGG19). Dadurch fokussiert das Training stärker auf visuell wahrnehmbare Strukturen, Texturen und Formen, anstatt auf reine Pixelübereinstimmung. Das Resultat sind schärfere und realistischere Bilder, wobei der PSNR oft leicht sinkt. Diese Methode eignet sich, um die Wahrnehmungsqualität zu verbessern und visuelle Details stärker zu betonen.

## 3. Adversarielles Training (SRGAN-basiertes Verfahren)

Das adversarielle Training kombiniert ein Super-Resolution-Netzwerk (Generator) mit einem Diskriminator, der versucht zu unterscheiden, ob ein Bild echt oder generiert ist. Dieses Verfahren erzwingt realistische Details und texturreiche Strukturen, was zu lebendigeren Ergebnissen führt. Allerdings ist das Training empfindlich und kann instabil werden, insbesondere bei kleinen oder flachen Netzwerken. Es zeigt jedoch sehr deutlich den Unterschied zwischen numerisch hoher und visuell realistischer Qualität.